

Теорема Мерсера и Метрические методы классификации

Функан 4 семестр

Кейс 2 и Кейс 5

[Google Colab](#)

Выполнили:

Зыков Макар Романович

Кулинич Павел Васильевич

Группа: J3211

ИСУ: 489608

466420

Санкт-Петербург, 2026

1. Кейс 2. Теорема Мерсера и матрицы Грама

1.1. Постановка задачи

Необходимо исследовать функции сходства и определить, какие из них могут использоваться как корректные ядра. Для конечной выборки строится матрица Грама G , после чего проверяется ее симметричность и положительная полуопределенность

$$G = \left(K(x_i, x_j) \right)_{\{i,j=1\}}^{\{ell\}}, \quad z^T G z \geq 0 \text{ для любого } z$$

Если существует отрицательное собственное значение $\lambda < 0$, то для соответствующего собственного вектора v выполнено $v^T G v = \lambda v^T v < 0$, значит условие положительной полуопределенности нарушается

1.2. Исследуемые функции сходства

$$K_{lin}(x,z) = x^T z$$

$$K_{rbf}(x,z) = \exp \left(-\gamma \|x - z\|^2 \right)$$

$$K_{delta}(x,z) = 1, \text{ если } x = z, \text{ и } 0 \text{ иначе}$$

$$K_{ne}(x,z) = 0, \text{ если } x = z, \text{ и } 1 \text{ иначе}$$

$$K_{sigma}(x,z) = \tanh(k_0 + k_1 x^T z)$$

1.3. Результаты




Рисунок 1 - Синтетическая двумерная выборка для проверки ядер

Таблица 1 - Проверка матриц Грама на синтетической выборке.

Функция сходства	$\ G-G^T\ _F$	$\lambda_{\min}$	Отриц. собств. знач.	PSD	$\min z^T G z$	Отриц. случ. тесты
Linear	0.0000	-5.57e-14	0	да	0.0862	0
RBF gamma=1	0.0000	2.10e-14	0	да	15.1719	0
Delta	0.0000	1.0000	0	да	59.9722	0
Not equal	0.0000	-1.0000	99	нет	-133.2759	329
Sigmoid k0=0, k1=1	0.0000	-3.6475	23	нет	-18.7631	34




Рисунок 2 - Спектры матриц Грама для исследуемых функций

Линейное, RBF и дельта-ядро дают неотрицательный спектр с учетом численной погрешности

Ядро несовпадения и сигмоидальное ядро при выбранных параметрах дают отрицательные собственные значения, поэтому нарушают PSD условие на рассмотренной выборке

Таблица 2 - Зависимость PSD свойства сигмоидального ядра от параметров k_0 и k_1

k_0	k_1	$\lambda_{\min}$	Отриц. собств. знач.	PSD
-1	-1.0000	-82.7017	43	нет
-1	0.1000	-74.4786	15	нет
-1	1.0000	-24.4006	43	нет
0	-1.0000	-92.5041	25	нет
0	0.1000	-0.1060	9	нет
0	1.0000	-3.6475	23	нет
1	-1.0000	-82.7460	43	нет
1	0.1000	-0.5188	10	нет
1	1.0000	-5.7044	42	нет




Рисунок 3 - Минимальное собственное значение сигмоидального ядра при разных параметрах

Таблица 3 - Проверка устойчивости вывода при изменении размера выборки

n	Функция сходства	lambda_min	Отриц. собств. знач.	PSD
20	Linear	-4.35e-15	0	да
20	RBF gamma=1	0.0003	0	да
20	Delta	1.0000	0	да
20	Not equal	-1.0000	19	нет
20	Sigmoid k0=0, k1=1	-0.8178	9	нет
50	Linear	-3.27e-14	0	да
50	RBF gamma=1	3.14e-09	0	да
50	Delta	1.0000	0	да
50	Not equal	-1.0000	49	нет
50	Sigmoid k0=0, k1=1	-1.9282	15	нет
100	Linear	-5.57e-14	0	да
100	RBF gamma=1	2.10e-14	0	да
100	Delta	1.0000	0	да
100	Not equal	-1.0000	99	нет
100	Sigmoid k0=0, k1=1	-3.6475	23	нет
200	Linear	-1.28e-13	0	да
200	RBF gamma=1	-3.67e-15	0	да
200	Delta	1.0000	0	да
200	Not equal	-1.0000	199	нет
200	Sigmoid k0=0, k1=1	-6.8792	34	нет




Рисунок 4 - Зависимость $\lambda_{\min}$ от размера выборки




Рисунок 5 - Спектральные вложения для PSD ядер

Таблица 4 - Дополнительная проверка на датасете Iris после стандартизации

Функция сходства	$\ G-G^T\ F$	$\lambda_{\min}$	Отриц. собств. знач.	PSD	Отриц. случ. тесты
Linear	0.0000	-1.62e-13	0	да	0
RBF gamma=1	0.0000	4.57e-18	0	да	0
Delta	0.0000	0.0000	0	да	0
Not equal	0.0000	-1.9868	148	нет	332
Sigmoid k0=0, k1=1	0.0000	-18.4574	74	нет	74

1.4. Выводы по кейсу 2

- Линейное, RBF и дельта ядро на рассмотренных выборках дают положительно полуопределенные матрицы Грама

- Ядро несовпадения нарушает условие Мерсера, потому что в спектре появляются отрицательные собственные значения
- Сигмоидальное ядро зависит от параметров и в общем случае не гарантирует положительную полуопределенность
- Случайная проверка $z^T G z$ полезна как дополнительная диагностика, но не заменяет спектральный анализ
- PSD проверка на одной выборке является эмпирическим подтверждением, но не полным доказательством для всех конечных выборок

2. Кейс 5. Метрические методы классификации

2.1. Постановка задачи

Требуется реализовать и исследовать метрические классификаторы. Объекты упорядочиваются по расстоянию до классифицируемого объекта, после чего класс выбирается по максимальной сумме голосов соседей

$$\rho(x, x_i) = \left(\sum_{j=1}^p w_j |x_j - x_{ij}| \right)^{\frac{1}{p}}, \quad w_j > 0, p \geq 1$$

$$a(x; X^{\text{ell}}) = \arg \max_{y \in Y} \Gamma_y(x), \quad \Gamma_y(x) = \sum_i [y_i = y] w(i, x)$$

2.2. Методика

Реализованы 1NN, kNN, weighted kNN, окно Парзена фиксированной ширины и окно Парзена переменной ширины. Параметры k, p, h и вид ядра K подбирались по полному скользящему контролю LOO. Эксперименты проведены на Iris, Wine, Breast Cancer Wisconsin и синтетическом make_moons

$$K_{\text{fixed}}: \sum_i [y_i = y] K \left(\frac{\rho(x, x_i)}{h} \right)$$

$$K_{\text{variable}}: \sum_i [y_i = y] K \left(\frac{\rho(x, x_i)}{\rho(x, x_{k+1})} \right)$$

Таблица 5 - Влияние стандартизации признаков на качество kNN при k=5

Датасет	LOO ошибка без масштабирования	Ассигасу без масштабирования	LOO ошибка после стандартизации	Ассигасу после стандартизации
Iris	0.0333	0.9667	0.0533	0.9467
Wine	0.3034	0.6966	0.0281	0.9719
Breast Cancer	0.0668	0.9332	0.0299	0.9701

Масштабирование признаков критично, без него признаки с большими численными диапазонами неявно получают больший вес в расстоянии

Таблица 6 - Подбор параметров по LOO-критерию

Датасет	best k kNN	LOO kNN	best k weighted	LOO weighted	best p	LOO npi best p	best h fixed	best K fixed	LOO fixed Parzen	best k variable	best K variable	LOO variable Parzen
Iris	13	0.0333	9	0.0467	1	0.0467	0.6270	gaussian	0.0400	15	uniform	0.0267
Wine	11	0.0225	7	0.0393	2	0.0281	1.6820	gaussian	0.0225	1	gaussian	0.0169
Breast Cancer	5	0.0299	13	0.0299	2	0.0299	0.8910	gaussian	0.0351	3	uniform	0.0281




Рисунок 6 - Зависимость LOO-ошибки от числа соседей k




Рисунок 7 - Зависимость LOO ошибки окна Парзена от ширины h на Iris




Рисунок 8 - Зависимость качества от параметра p в метрике Минковского

Малые значения k и h дают локальное, но шумочувствительное решение, а большие значения сглаживают границу, однако при чрезмерном росте могут размывать структуру классов




Рисунок 9 - Карты классификации kNN на take_toons при разных k




Рисунок 10 - Карты классификации окна Парзена при разных h

Таблица 7 - Сравнение kNN и $weighted-kNN$ на задаче с шумом и выбросами

k	Accuracy kNN	Accuracy weighted-kNN
1.0000	0.7550	0.7550
3.0000	0.7850	0.7550
5.0000	0.7825	0.7775
7.0000	0.7600	0.7775
9.0000	0.7775	0.7850
11.0000	0.7850	0.7900
15.0000	0.7675	0.7950
21.0000	0.7775	0.7900




Рисунок 11 - Устойчивость weighted kNN относительно обычного kNN

Weighted kNN устойчивее в задачах с шумом и выбросами, потому что дальние соседи получают меньшие веса и слабее влияют на итоговое решение

Таблица 8 - Профиль компактности и качество 1NN

Датасет	Среднее $\Pi(1..10)$	1NN LOO accuracy
Iris	0.0867	0.9467
Wine	0.0758	0.9551
Breast Cancer	0.0652	0.9508




Рисунок 12 - Профили компактности реальных датасетов

Корреляция между средним профилем компактности $P_i(1..10)$ и 1NN LOO ассурасу в эксперименте составила -0.495, чем меньше профиль компактности, тем чаще ближайшие соседи принадлежат тому же классу

Таблица 9 - Сравнение полного 1NN и 1NN по эталонам

Датасет	Метод	Число эталонов	Test accuracy	Время предсказания, мс
Iris	Полная выборка 1NN	73	0.9111	0.4480
Iris	Удаление эталонов	9	0.8889	0.2170
Iris	Добавление эталонов	40	0.8889	0.2250
Wine	Полная выборка 1NN	86	0.9259	0.5310
Wine	Удаление эталонов	9	0.9074	0.1920
Wine	Добавление эталонов	40	0.8889	0.2920
Breast Cancer	Полная выборка 1NN	278	0.9474	21.0200
Breast Cancer	Удаление эталонов	6	0.9240	0.5480
Breast Cancer	Добавление эталонов	40	0.9591	1.3710




Рисунок 13 - Уменьшение числа эталонов при жадном отборе

2.3. Выводы по кейсу 5

- Число соседей k управляет компромиссом между переобучением и сглаживанием границы решения
- Стандартизация признаков является обязательной практикой для метрических методов на разномасштабных числовых признаках
- Оптимальный параметр p зависит от геометрии данных, поэтому его следует выбирать по LOO
- Ширина окна Парзена h задает степень сглаживания, слишком малое h повышает чувствительность к шуму, слишком большое h размывает классы
- Weighted kNN полезен при выбросах и локальном шуме
- Профиль компактности является интерпретируемой диагностикой применимости 1NN
- Жадный отбор эталонов ускоряет классификацию при умеренном изменении качества

3. Общие выводы

Оба кейса показывают, что качество алгоритма определяется выбранной геометрией данных. В кейсе 2 геометрия задается ядром и проверяется через PSD свойство матрицы Грама. В кейсе 5 геометрия задается метрикой, масштабированием, параметром p , числом соседей и шириной окна

- Корректное ядро должно порождать положительно полуопределенную матрицу Грама
- Метрические классификаторы просты, но чувствительны к масштабу признаков, шуму и выбору параметров
- LOO контроль позволяет согласованно выбирать параметры для малых и средних выборок
- Графики спектров, границ решения, профилей компактности и таблицы параметров делают результаты интерпретируемыми