

Кейс 2: теорема Мерсера

Во многих прикладных задачах объекты удобно сравнивать не напрямую по координатам, а через функцию сходства

$$K(x, z), \quad x, z \in X$$

Такая функция используется в методах опорных векторов, ядровой регрессии, kernel PCA, спектральной кластеризации и других алгоритмах. Идея состоит в том, что вместо явного перехода в новое признаковое пространство можно работать только со значениями функции $K(x, z)$.

Если существует отображение

$$\psi : X \rightarrow H$$

где H – пространство со скалярным произведением, такое что

$$K(x, z) = \langle \psi(x), \psi(z) \rangle$$

то функция K называется ядром.

Тем самым ядро задаёт скалярное произведение в некотором пространстве признаков. Это делает ядровые методы способом нелинейного анализа данных без явного построения новых признаков.

Теорема Мерсера даёт критерий, когда функция двух аргументов действительно может использоваться как ядро.

Функция $K(x, z)$ является ядром тогда и только тогда, когда выполнены два условия:

1. симметричность:

$$K(x, z) = K(z, x)$$

2. неотрицательная определённость:

$$\int_X \int_X K(x, z) g(x) g(z) dx dz \geq 0$$

для любой функции $g : X \rightarrow \mathbb{R}$

В вычислительной практике чаще используется эквивалентная конечномерная формулировка. Для любой конечной выборки

$$X_n = (x_1, \dots, x_n)$$

строится матрица Грама

$$G = (G_{ij})_{i,j=1}^n, \quad G_{ij} = K(x_i, x_j)$$

Тогда условие Мерсера эквивалентно тому, что для любой конечной выборки матрица G должна быть положительно полуопределённой, то есть

$$z^T G z \geq 0 \quad \forall z \in \mathbb{R}^n$$

Отсюда следует удобный вычислительный критерий: если у матрицы Грама появляются отрицательные собственные значения, то на данной выборке ядро нарушает условие Мерсера.

Задания для работы

1. Выбрать семейство исследуемых функций

Рассмотреть не менее четырёх функций сходства, среди которых должны быть:

- хотя бы два кандидата, которые ожидаемо удовлетворяют условию Мерсера
- хотя бы два кандидата, для которых возможно нарушение условия Мерсера.

Рекомендуемый набор:

$$K_{\text{lin}}(x, z) = x^T z$$

$$K_{\text{rbf}}(x, z) = \exp(-\gamma \|x - z\|^2)$$

$$K_{\delta}(x, z) = \begin{cases} 1, & x = z \\ 0, & x \neq z \end{cases}$$

$$K_{\neq}(x, z) = \begin{cases} 0, & x = z \\ 1, & x \neq z \end{cases}$$

$$K_{\sigma}(x, z) = \tanh(k_0 + k_1 x^T z)$$

2. Сформулировать предварительную гипотезу: какие функции являются ядрами, а какие нет
3. Построить данные и матрицы Грама

Пусть дана выборка

$$X_n = (x_1, \dots, x_n), \quad x_i \in \mathbb{R}^n$$

Для каждого ядра построить матрицу Грама

$$G = (G_{ij})_{i,j=1}^n, \quad G_{ij} = K(x_i, x_j)$$

4. Реализовать построение матрицы Грама для выборки
5. Найти величину нессимметричности

$$\|G - G^T\|_F$$

6. Найти собственные значения матрицы G
7. Найти минимальное собственное значение $\lambda_{\min}(G)$
8. Указать число отрицательных собственных значений с учётом численного порога
9. Проверить условие Мерсера численно

- (a) объяснить аналитически, почему отрицательное собственное значение означает нарушение условия Мерсера на данной выборке
- (b) пояснить, почему положительная полуопределённость на одной выборке ещё не доказывает теорему Мерсера в полном виде
- (c) для каждого ядра проверить условие

$$\lambda_{\min}(G) \geq -\varepsilon$$

- (d) дополнительно выполнить случайный тест: сгенерировать несколько случайных векторов z и вычислить значения

$$z^T G z$$

- (e) сравнить результаты спектральной проверки и случайного теста

10. Исследовать влияние параметров ядра

Особый интерес представляет сигмоидальное ядро

$$K_{\sigma}(x, z) = \tanh(k_0 + k_1 x^T z).$$

- (a) сформулировать, почему в зависимости от параметров k_0 и k_1 функция может вести себя по-разному

- (b) пояснить, почему для отрицательных k_0 или k_1 можно ожидать нарушение условия Мерсера
- (c) выбрать сетку параметров, например

$$k_0 \in \{-1, 0, 1\}, \quad k_1 \in \{-1, 0.1, 1\}$$

- (d) для каждой пары параметров построить матрицу Грама
- (e) вычислить её минимальное собственное значение
- (f) представить результаты в таблице или в виде тепловой карты

11. Исследовать зависимость от данных и размера выборки

- (a) провести проверку для нескольких размеров выборки, например $n = 20, 50, 100, 200$
- (b) сравнить спектр матриц Грама
- (c) исследовать, как меняется $\lambda_{\min}(G)$ при росте n

12. Объяснить, почему для положительно полуопределённой матрицы Грама возможно разложение Холецкого или спектральное разложение без отрицательных собственных значений

13. Построить двумерную визуализацию объектов через спектральное вложение по положительным собственным значениям матрицы Грама

Данные для работы

1. Синтетические данные

Использовать синтетическую выборку в $\mathbb{R}^2$ или $\mathbb{R}^3$.

Например, можно сгенерировать две группы точек:

$$X^{(1)} \sim \mathcal{N}(\mu_1, \sigma^2 I), \quad X^{(2)} \sim \mathcal{N}(\mu_2, \sigma^2 I)$$

где

$$\mu_1 = (-1, -1), \quad \mu_2 = (1, 1)$$

Итоговая выборка состоит из объединения двух облаков.

Также можно взять одномерную выборку

$$x_i \in [-2, 2]$$

и задать её либо равномерно, либо случайно.

2. Известные датасеты

Можно использовать небольшой реальный набор числовых объектов, например классический набор Iris или Wine.